

COMENTÁRIOS: PROJETO_FINAL - CLÁUDIA MARIA DUARTE RAMOS

Objetivo do trabalho

O objetivo deste projeto foi aplicar conceitos de SQL, Python e Análise Exploratória de Dados (EDA) para compreender o comportamento dos dados da base Human Resources (HR), identificando padrões, estatísticas descritivas, distribuição salarial, diferenças entre departamentos e regiões, além da detecção de possíveis valores atípicos (outliers). Todo o processo foi documentado e automatizado, gerando relatórios, gráficos e arquivos de saída para apoiar futuras análises.

Etapas desenvolvidas

O projeto foi estruturado em etapas sequenciais:

1. Acesso ao banco de dados <https://freesql.com/#> para consultar a tabela sugerida (HR) Human Resources e tabelas relacionadas (EMPLOYEES, DEPARTMENTS e JOBS e EMPLOYEES, DEPARTMENTS, LOCATIONS, COUNTRIES e REGIONS) aplicando os filtros sugeridos.
2. Feitas queries para atender os critérios propostos no projeto HR.
3. Download dos arquivos gerados para rodar no VS code (python).
4. Importação das bibliotecas e configuração do ambiente em python.
5. Leitura das consultas SQL exportadas em formato CSV (Query_01 e Query_02) e importados no Python para a execução de uma Análise Exploratória de Dados (EDA).
6. Padronização dos nomes das colunas.
7. Diagnóstico inicial da qualidade dos dados, verificando dimensões, tipos de dados, valores ausentes e registros duplicados.
8. Geração automática de relatórios exploratórios utilizando a biblioteca Sweetviz.
9. Aplicação de análises exploratórias para responder perguntas de negócio.
10. Cálculo de medidas estatísticas básicas.
11. Construção de histogramas e boxplots para identificação de padrões e outliers.
12. Identificação e separação dos outliers utilizando o método do Intervalo Interquartil (IQR).
13. Exportação dos resultados tratados para novos arquivos CSV.
14. Elaboração do README com a documentação do projeto.

Principais resultados encontrados

Qualidade dos dados

A **Query_01** apresentou uma base enxuta, composta por **106 registros e 3 variáveis**, sem valores ausentes, porém contendo **24 registros duplicados**. A **Query_02** possui **122 registros e 5 variáveis**, apresentando **16 valores ausentes** nas colunas **Funcionário** e **Salário**, sem ocorrência de registros duplicados. Essas verificações permitiram avaliar previamente a consistência dos dados antes da realização das análises.

Distribuição dos colaboradores

A análise mostrou que a maior concentração de colaboradores está no **Departamento 50**, com **45 funcionários**, seguido pelo **Departamento 80**, com **34 colaboradores**. Em relação à distribuição geográfica, observou-se predominância da região **Americas**, com **70 funcionários**, enquanto a região **Europe** possui **36 colaboradores**. Além disso, a maior quantidade de funcionários por departamento está concentrada no Departamento 50 (45 funcionários), seguindo do Departamento 80 (34 funcionários).

Análise salarial

A remuneração média geral encontrada foi de aproximadamente R\$ 6456,75, enquanto a mediana foi de R\$ 6.150,00, indicando que metade dos colaboradores recebe salários inferiores a esse valor. Os quartis mostram que:

- 25% recebem até R\$ 3.100,00
- 50% recebem até R\$ 6.150,00
- 75% recebem até R\$ 8.950,00

Esses resultados indicam que a maior concentração salarial está situada entre R\$ 3.100,00 e R\$ 8.950,00

Comparação entre departamentos

A análise evidenciou que o departamento Executive possui a maior média salarial da organização, aproximadamente R\$ 19.333,33, refletindo cargos executivos de alta responsabilidade, enquanto funções operacionais como **Shipping Clerk**, **Stock Clerk** e **Purchasing Clerk** apresentam as menores médias salariais. . Na análise por cargo, destacam-se:

1. President: R\$ 24.000,00
2. Administration Vice President: R\$ 17.000,00
3. Shipping Clerk: R\$ 3.215,00

4. Stock Clerk: R\$ 2.785,00
5. Purchasing Clerk: R\$ 2.780,00

Comparação por região

Apesar da região **Americas** concentrar o maior número de colaboradores, a região **Europe** apresentou a maior média salarial (**R\$ 8.916,67**), superior à média da região **Americas** (**R\$ 5.191,66**). Esse resultado demonstra que quantidade de funcionários não implica necessariamente maior remuneração média.

Identificação de outliers

Foi utilizado o método do **Intervalo Interquartil (IQR)** para identificar salários fora do comportamento esperado da distribuição. Os limites encontrados foram:

- Limite inferior: **-R\$ 5.675,00**
- Limite superior: **R\$ 17.725,00**

Foi identificado apenas **um outlier** em ambas as consultas.

****Quando a distribuição dos salários é muito concentrada em valores menores, a conta pode resultar em um limite inferior negativo. Isso não significa que existam salários negativos, apenas que, nesse caso, não há outliers inferiores, já que o menor salário possível é R\$ 0.**

Na **Query_01**, o salário de **R\$ 24.000** do cargo **President** foi classificado como valor atípico.

Na **Query_02**, o funcionário **Steven**, pertencente ao Departamento **90**, também apresentou salário de **R\$ 24.000,00**, sendo identificado como outlier.

A Query 2 traz só o código do departamento (90). A Query 1, que já vem com nome, mostra diretamente que "Executive" é o departamento com maior média salarial: R\$ 19.333,33 — o valor exato apurado para o departamento 90 na Query 2. Isso confirma, com as duas fontes concordando, que departamento 90 = Executive, e explica por que ele aparece isolado, bem acima dos demais, em todos os boxplots por categoria.

Os arquivos contendo os registros com e sem outliers foram exportados automaticamente para utilização em análises futuras.

Principais insights obtidos

1. O departamento Executive concentra a maior média salarial da empresa** (R\$ 19.333,33), confirmado diretamente por nome (Query 1) e por código (Query 2, departamento 90).
2. A região Europe tem média salarial 72% maior que Americas** (R\$ 8.916,67 vs R\$ 5.191,66), apesar de ter praticamente metade do número de funcionários (36 vs 70).
3. O departamento de código 50 (perfil operacional/Shipping) concentra 42% de toda a força de trabalho** (45 de 106 funcionários).
4. O ranking de cargos por salário reflete uma hierarquia organizacional clara**: da Presidência (R\$ 24.000,00) até cargos operacionais de estoque e compras (+/-2.780) — uma diferença de mais de 8,6x entre o maior e o menor.
5. 16 departamentos (13% da base) não possuem nenhum funcionário vinculado** — sinal relevante para gestão de RH sobre estrutura organizacional subutilizada ou em expansão.
6. Um único outlier salarial real** foi identificado estatisticamente em cada query (método IQR), e é o mesmo funcionário/cargo nas duas — plenamente justificável pelo cargo de Presidência. As duas queries se validam mutuamente**: a igualdade estatística exata do salário entre elas confirma que ambas consultam corretamente a mesma base de funcionários, apenas sob perspectivas diferentes (cargo/departamento vs. pessoa/região).

Conclusão

O projeto demonstrou a aplicação integrada de **SQL, Python, Pandas, Seaborn, Matplotlib e Sweetviz** para transformar dados brutos em informações úteis para apoio à tomada de decisão. Por meio da Análise Exploratória de Dados foi possível avaliar a qualidade da base, identificar padrões de remuneração, diferenças entre departamentos e regiões, detectar valores atípicos e produzir evidências quantitativas que auxiliam na compreensão do cenário organizacional. O processo foi automatizado e documentado, fornecendo uma base sólida para análises mais avançadas ou para a construção de dashboards de Business Intelligence. Além da EDA, foi realizado um processo de debug e validação do código, corrigindo erros de execução, padronizando variáveis, validando os resultados estatísticos e garantindo a geração correta dos arquivos e gráficos produzidos pelo projeto.